

# Derin Öğrenme Algoritmaları ile Beyin Tümörü Sınıflandırma

## Brain Tumor Classification Using Deep Learning Algorithms

Meltem Kurt Pehlivanoğlu  
Kocaeli Üniversitesi  
Bilgisayar Mühendisliği Bölümü  
Kocaeli, Türkiye  
meltem.kurt@kocaeli.edu.tr

Ayşe Gül Eker  
Kocaeli Üniversitesi  
Bilgisayar Mühendisliği Bölümü  
Kocaeli, Türkiye  
aysegul.eker@kocaeli.edu.tr

İbrahim İnce  
Kocaeli Üniversitesi  
Bilgisayar Mühendisliği Bölümü  
Kocaeli, Türkiye  
200202102@kocaeli.edu.tr

Deniz Karhan  
Kocaeli Üniversitesi  
Bilgisayar Mühendisliği Bölümü  
Kocaeli, Türkiye  
200202005@kocaeli.edu.tr

Nevcihan Duru  
Kocaeli Sağlık ve Teknoloji Üniversitesi  
Bilgisayar Mühendisliği Bölümü  
Kocaeli, Türkiye  
nevcihan.duru@kocaelisaglik.edu.tr

**Öz**—Beyin tümörü sınıflandırması, beyin tümörlerini çeşitli özelliklerine göre sınıflandırır. Uygun tedavi stratejilerinin belirlenmesine ve hasta sonuçlarının tahmin edilmesine yardımcı olur. Bu nedenle, bu çalışmanın amacı, yakın zamanda yayınlanan bir tümör sınıflandırma veri kümesi üzerinde çeşitli Evrişimsel Sinir Ağı (CNN) tabanlı derin öğrenme modellerini kullanarak (birleştirilmiş modeller dahil) optimal tümör sınıflandırma modelini belirlemektir. Ayrıca, çeşitli görüntü manipülasyonu ve artırma teknikleri uygulanmış ve bunların model performansı üzerindeki etkisi değerlendirilmiştir. Deneyel sonuçlar, birleştirilmiş derin öğrenme modellerinin çoklu beyin tümörü sınıflandırmada performans açısından diğer yaklaşımlardan daha iyi olduğunu kanıtlar.

**Anahtar Sözcükler**—tümör sınıflandırma; beyin tümörü; makine öğrenmesi; derin öğrenme.

**Abstract**—Brain tumor classification categorizes brain tumors based on their various characteristics. It aids in determining suitable treatment strategies and predicting patient outcomes. Therefore, the objective of this study is to identify the optimal tumor classification model by utilizing various Convolutional Neural Network (CNN)-based deep learning models (including combined models) on a recently published tumor classification dataset. Furthermore, diverse image manipulation and augmentation techniques were applied and their impact on model performance was evaluated. The experimental results prove that the combined deep learning models outperform other approaches in terms of performance in multi-class brain tumor classification.

**Keywords**—tumor classification; brain tumor; machine learning; deep learning.

### I. GİRİŞ

Beyin tümörleri, beyin hücrelerinin kontrolsüz bir şekilde çoğalmasıyla oluşan kitlelerdir. Beyin tümörlerinin sınıflandırılması ve erken teşhisi, tıbbi görüntüleme alanında önemli bir araştırma alanıdır. Tümör sınıflandırmada, iyi

ve kötü huylu tümör sınıflandırmanın yanı sıra, Dünya Sağlık Örgütü (DSÖ) tarafından kabul edilen tümörlerin agresiflik derecelerine göre sınıflandırılması da kullanılan yöntemlerdendir. Bu sınıflandırmada Grade I ve Grade II düşük dereceli tümörleri temsil ederken, Grade III ve Grade IV sırasıyla yüksek dereceli ve en yüksek dereceli tümörleri temsil eder [1].

Medikal görüntüleme tekniklerindeki hızlı ilerlemeler ve yapay zeka algoritmalarının gelişimi, beyin tümörlerinin sınıflandırılmasında yeni yaklaşımlar sunmaktadır. Bu yaklaşımların temel taşlarından biri manyetik rezonans görüntülemesidir (MRI), MRI ile yüksek çözünürlüklü beyin dokusu görüntülenebilir. Bu görüntüler beyin tümörlerinin sınıflandırılması için, tümörlerin yapısal özelliklerinin analizinde önemli bir araç haline gelmiştir. MRI üzerinden, tümörün büyüklüğü, şekli, iç yapısı ve diğer dokularla ilişkisi gibi birçok veri gözlemlenebilir.

Literatürdeki çalışmalar incelendiğinde, CNN tabanlı derin öğrenme modelleri beyin tümörlerinin sınıflandırılmasında önemli bir başarı elde etmiştir. Bu modeller, görüntülerin özelliklerini otomatik olarak çıkarır ve farklı tümör tiplerini doğru bir şekilde tanımak için eğitilir. Ayrıca, transfer öğrenme ve topluluk öğrenme (ensemble learning) gibi teknikler de kullanılarak modellerin performansları artırılmaktadır.

#### A. Motivasyon ve Katkı

Bu çalışmada, 2023 yılında Kaggle üzerinden paylaşılan T1, T1C+ ve T2 sekanslarında 14 farklı beyin tümörüne ait MRI görüntülerini içeren veri kümesi [2] kullanılmıştır. Literatürde bu veri kümesini kullanarak tümör sınıflandırması yapan bir çalışmaya rastlanmamış olup, bu kapsamda bu çalışma ileriki çalışmalar için önemli bir referans sağlayacaktır. Çalışmada, BasicResNet [3], BasicVGG [4], EfficientNetB0, Efficient-

NetB3, EfficientNetB5, EfficientNetV2B0 [5], DenseNet121 [6], InceptionResNetV2 [7], InceptionV3 [8], MobileNetV2 [9], ResNet101 [3], Resnet101V2 [8], VGG-16, VGG-19 [4], Xception [10] modelleri veri kümesi üzerine uygulanarak 14 ve 44 sınıf olmak üzere iki farklı çoklu sınıflandırma gerçekleştirilmiştir. Çalışmada 14 sınıf için en başarılı model doğruluk, F1-skor, kesinlik ve hassasiyet metrikleri için sırasıyla; %99.55, %99.39, %98.69, %98.66 değerlerine sahiptir. 44 sınıf için ise aynı metrikler için sırasıyla; %98.36, %98.34, %96.17 ve %95.98 başarımları elde edilmiştir. Çalışmanın kaynak kodları GitHub üzerinde [11] erişime açık olarak sunulmuştur.

## B. Organizasyon

Çalışmanın ikinci bölümünde son yıllarda literatürde yer alan, beyin tümörü sınıflandırması amaçlı, makine öğrenmesi ve derin öğrenme yöntemlerini kullanan çalışmalar verilmiştir. Üçüncü bölümde ise kullanılan veri kümesi detaylandırılmış, dördüncü bölümde beyin tümörü tespiti için kullanılan yöntemler kapsamlı olarak sunulmuştur. Beşinci bölümde elde edilen deneysel sonuçlar detaylandırılarak, son bölümde ise elde edilen sonuçlar değerlendirilmiştir.

## II. İLGİLİ ÇALIŞMALAR

Bu bölümde, literatürde yer alan makine öğrenmesi ve derin öğrenme tabanlı beyin tümör sınıflandırılması yapan çalışmalar kapsamlı olarak incelenmiştir.

Alanazi ve arkadaşları 2021 yılındaki çalışmalarında [12], beyin tümörü tespiti için pituitary, meningioma ve glioma gibi alt sınıflara ayrılan yeni bir transfer derin öğrenme modeli önermişlerdir. Başlangıçta, çeşitli katmanlardan oluşan izole edilmiş CNN modelleri oluşturulmuştur. 22 katmanlı izole edilmiş CNN modeli [13]'de verilen veri kümesi üzerinde ikili sınıflandırma için kullanılırken, çoklu sınıflandırma için ise transfer öğrenme kullanılmıştır. Geliştirilen transfer öğrenen model ile aynı veri kümesi üzerinde %95,75 doğruluk oranı elde edilmiştir. Ayrıca, geliştirilen transfer öğrenen modelin gerçek zamanlı uygulamalar için uyumluluğunu, yeteneklerini ve güvenilirliğini doğrulamak amacıyla, [14]'de verilen veri kümesi üzerinde başarımları test edilmiş, %96,89 doğruluk oranı elde edilmiştir.

Artzi ve arkadaşları 2021 yılındaki çalışmalarında [15], çalışmalarında verilen veri kümesi üzerinde üç posterior fossa tümörünü sınıflandırmak için önceden eğitilmiş bir ResNet-50 CNN mimarisi önermişlerdir. Veri kümesi, 22 sağlıklı, 63 PA (Pilocytic Astrocytoma), 57 MB (Medulloblastoma) ve 16 EP (Ependymoma) hastasının 158 MRI görüntüsünü içermektedir. Çalışmada, görüntülerin mekansal olarak hizalanmasını sağlamak için görüntü ortak kaydı, görüntüden yoğunluk gradyanını kaldırmak için ise bias alan düzeltilmesi yapılmıştır. Veri kümesinin boyutunu ve çeşitliliğini artırmak için çevirme, yansıtma, döndürme ve yakınlaştırma gibi veri artırma yöntemleri kullanılmıştır. Önerilen CNN modeli ile, test veri kümesi üzerinde %88 doğruluk oranı elde edilmiştir.

Guzmán ve arkadaşları 2022 yılındaki çalışmalarında [16], beyin tümörü sınıflandırması için genel bir CNN mod-

elinin yanı sıra, altı farklı önceden eğitilmiş CNN modelleri (ResNet50, InceptionV3, InceptionResNetV2, Xception, MobileNetV2 ve EfficientNetB0) kullanmışlardır. Çalışmada, MSOUD[17], FIGSHARE[14], SARTAJ[18] ve Br35H[19] veri kümeleri kullanılmıştır. Birleştirilen bu veri kümeleri glioma, meningioma ve hipofiz tümörleri ile sağlıklı beyin görüntülerini içerir. En iyi doğruluk oranı %97,12 InceptionV3 ile elde edilmiştir.

İrmak'ın 2022 yılında yapmış olduğu çalışmada [20], üç farklı tümör sınıflandırması için üç farklı CNN modeli geliştirilmiştir. İlk CNN modelinde, RIDER [21] veri kümesi kullanılarak, tümörlü (1640) ve tümörsüz (1350) olmak üzere ikili sınıflandırma yapılmış olup, %99.33 doğruluk oranı elde edilmiştir. İkinci CNN modelinde ise, REMBRANDT [22] veri kümesi kullanılarak normal (850), glioma (950), meningioma (700), hipofiz (700) ve metastatik (750) olmak üzere dört sınıf için %92.66 doğruluk oranı elde edilmiştir. Üçüncü CNN modelinde, TCGA-LGG [23] veri kümesi kullanılarak beyin tümörleri II. Derece (1676), III. Derece (1218) ve IV. Derece (1676) olmak üzere üç sınıfta toplanarak, %98.14 doğruluk oranı elde edilmiştir.

Rasool ve arkadaşları 2022 yılındaki çalışmalarında [24], [14]'de verilen veri kümesi üzerinde (426 glioma, 708 meningioma, 930 hipofiz tümörü ve 396 normal) üç farklı beyin tümörü ve normal görüntü sınıflandırması için yeni bir hibrit CNN tabanlı bir mimari önermişlerdir. Önerilen yöntem, CNN tabanlı özellik çıkarımı için önceden eğitilmiş bir Google-Net modelini SVM (Destek Vektör Makinesi) ile desen sınıflandırması için birleştiren birinci yöntemi ve ince ayarlanmış bir Google-Net'i soft-max sınıflandırıcı ile entegre eden ikinci yöntemi hibrit olarak kullanır. Çalışmada, Google-Net %93.1 doğruluk başarımları sağlarken, Google-Net'in bir özellik çıkarıcısı olarak SVM sınıflandırıcısıyla birlikte kullanımı, sınıflandırma doğruluğunu %98.1'e yükseltmiştir.

Aurna ve arkadaşları 2022 yılındaki çalışmalarında [25], üç farklı beyin tümörü (menenjiom, gliom, hipofiz) ve normal beyin görüntü sınıflandırması gerçekleştirmişlerdir. Çalışmada, VGG-19, EfficientNet-B0, Inception-V3, ResNet-50 ve Xception modellerinin yanı sıra önerilen CNN modeli arasından en iyi modeller seçilmiş ve öznetelik çıkarımı iki aşamada birleştirilmiştir. Çıkarılan özneteliklerden, Temel Bileşenler Analizi (PCA-Principal Component Analysis) kullanılarak en önemli öznetelikler seçilmiş ve sınıflandırıcıya beslenmiştir. Çalışmada, 3064 görüntüye sahip ilk veri kümesi [26] üzerinde %99,67, 3264 görüntünün kullanıldığı ikinci veri kümesi [27] üzerinde %98,16, 4292 görüntüye sahip üçüncü veri kümesi [18] üzerinde %99,76 ve tüm görüntülerin birleştirilmesi ile elde edilen veri kümesi üzerinde ise %98,96 doğruluk değerleri elde edilmiştir.


Raza ve arkadaşları 2022 yılındaki çalışmalarında [28], CNN mimarisi tabanlı glioma, meningioma ve hipofiz tümörü sınıflandırması için DeepTumorNet adlı bir hibrit derin öğrenme modeli önermişlerdir. CNN modelinin temeli olarak GoogLeNet mimarisi kullanılmıştır. Hibrit DeepTumorNet yaklaşımını geliştirirken, GoogLeNet'in son 5 katmanı çıkarılmış ve bu 5 katmanın yerine 15 yeni katman

eklenmiştir. DeepTumorNet %99.67 doğruluk, %99.6 hassasiyet, %100 hatırlama ve %99.66 F1 değerleriyle en başarılı model olmuştur.

Literatürdeki çalışmalar incelendiğinde, özellikle CNN tabanlı modellerin beyin tümör sınıflandırmasındaki başarısı açıktır, bu nedenle bu çalışma kapsamında da CNN tabanlı modeller kullanılmıştır. Bunun yanı sıra [2]'de verilen veri kümesini kullanan çalışmaya rastlanmamıştır.

### III. VERİ KÜMESİ ÖZELLİKLERİ

Bu çalışmada [2]'de verilen veri kümesi kullanılmaktadır. MRI görüntüleri T1, kontrastlı T1 (T1C+) ve T2 görüntülerinden oluşur. Şekil 1'de örnek olarak glioblastoma tümörüne ait aynı beyinden elde edilmiş sırasıyla T1, T1C+ ve T2 sekans MRI görüntüleri verilmiştir.



Şekil. 1. Glioblastoma T1, T1C+, T2 MR görüntüsü.

Veri kümesi astrocytoma, carcinoma, ependymoma, ganglioglioma, germinoma, glioblastoma, granuloma, medulloblastoma, meningioma, neurocytoma, oligodendroglioma, papilloma, schwannoma, tuberculoma ve normal (tümörsüz) olmak üzere 15 sınıfı (14 farklı beyin tümörü ve tümörsüz görüntüler) içerir ve toplam 4479 görüntüye sahiptir. Çalışmada kullanılan veri kümesindeki T1, T1C+ ve T2 MRI görüntülerinin sayısal dağılımı Tablo I'de verilmiştir.

TABLE I  
KULLANILAN VERİ KÜMESİNDE YER ALAN TÜMÖR SINIFLARI

justification=centering

Sınıf	MRI Görüntü Sayısı	T1	T1C+	T2
Astrocytoma	176	233	171	
Carcinoma	66	112	73	
Ependymoma	45	48	57	
Ganglioglioma	20	18	23	
Germinoma	27	40	33	
Glioblastoma	55	94	55	
Granuloma	30	31	17	
Medulloblastoma	23	67	41	
Meningioma	272	369	233	
Neurocytoma	130	223	104	
Oligodendroglioma	86	72	66	
Papilloma	66	108	63	
Schwannoma	148	194	123	
Tuberculoma	28	84	33	
Normal (Tümörsüz)	251	-	271	

Çalışma kapsamında bu veri kümesi 15 sınıf ve 44 sınıf olmak üzere iki farklı sınıflandırma başarısı açısından ele alınmıştır. 15 sınıf için; T1, T1C+ ve T2 sekans görüntüleri her tümör tipi için birleştirilerek, 14 farklı beyin tümörü sınıfı ve normal (tümörsüz) etiketleri olmak üzere toplam 15 sınıf etiketi kullanılmıştır. 44 sınıf için ise; tümör tipinin yanı sıra T1, T1C+ ve T2 sekans görüntüleri de ayrı birer sınıf olarak ele alınmıştır. Tablo I'den de görüleceği gibi normal sınıfına ait T1C+ sekans görüntüleri yer almamaktadır, bu nedenle toplamda 44 (= (14 × 3) + (1 × 2)) sınıf etiketi oluşturulmuştur.

### IV. YÖNTEM

Çalışmada beyin tümörü sınıflandırması için kullanılan modellere ait kapsamlı bilgiler aşağıda verilmiştir.

#### A. Veri Önileme

Beyin MR görüntülerini işlemek için tüm görüntüler ait oldukları sınıflara ayrılmıştır. MR görüntüleri, rastgele olarak karıştırılmış görüntülerin %70'i eğitim, %15'i sağlama, geriye kalan %15'i ise test kümesi için ayrılmıştır.

Veri kümesindeki sınıflar ve sahip oldukları görüntü sayıları incelendiğinde veri sayılarının standart sapmasının oldukça yüksek olduğu gözlenmiştir. Bu durumun model başarımına olumsuz etkilerini en aza indirebilmek için çeşitli veri sayısı artırma işlemleri uygulanmıştır. Bu işlemlerin yanı sıra mevcut görüntüler üzerine farklı manipülasyon işlemleri uygulanmıştır. Uygulanan işlemler aşağıda verilmiştir:

- MR görüntülerindeki beyin görüntüsünün etrafındaki fazlalık alan kırılmıştır. OpenCV kütüphanesi kullanılarak görüntülerdeki görüntüler yok edildikten sonra, piksel renk eşikleri düzenlenmiştir. Sonrasında görüntülere ait sınırlar bulunarak görsel etrafındaki fazlalık alanlar kırılmıştır.
- Mevcut MR görüntüleri üzerinde manipülatif işlemler uygulanmıştır.
- Mevcut orijinal MR görüntü sayısını artırma amaçlı yeni üretilmiş görüntüler veri kümesine eklenmiştir.
- Veri kümesinin tamamına Min-Maks ölçeklendirmesi yapılmıştır. (rescale=1.0/255.0).

Manipülasyon ve veri artırma işlemlerinde Tablo II'de verilen parametreler kullanılmıştır.

TABLE II  
VERİ ÖNİŞLEMEDE KULLANILAN HİPER PARAMETRELER

Yapılan İşlem	Hiper Parametre
Manipulasyon#1	(rotation range=30, width shift range=0.2, height shift range=0.2, brightness range=(0.2, 0.8), zoom range=0.2, channel shift range=(0.2, 0.2))
Manipulasyon#2	(rescale=1.0/255.0)
VeriArtırma#1	(VerticalFlip(always_apply=True), HorizontalFlip(always_apply=True), RandomBrightnessContrast(always_apply=True), RandomGamma(always_apply=True), Rotate(limit=30, always_apply=True))
VeriArtırma#2	(VerticalFlip(always_apply=True), HorizontalFlip(always_apply=True), RandomBrightnessContrast(always_apply=True), RandomGamma(always_apply=True))
VeriArtırma#3	(VerticalFlip(always_apply=True), HorizontalFlip(always_apply=True),

#### B. Yeni Veri Kümelerinin Oluşturulması

Orijinal veri kümesi üzerinde yapılacak her işlemin (manipülasyon, veri artırma) başarı oranlarına etkisini gözlemleyebilmek için orijinal veri kümesinden yeni veri kümeleri üretilmiştir. Üretilen veri kümeleri sınıflandırma modellerine girdi olarak verilmek üzere, MR görüntüleri "ImageDataGenerator" kullanılarak 16 veya 32'şerlik yığınlardan (batch\_size) oluşacak şekilde düzenlenmiştir. Bunun yanı sıra veri kümelerine Tablo II'de verilen ön işlemler uygulanmıştır. Oluşturulan veri kümelerine ait özellikler Tablo III'de ayrıntılı olarak verilmiştir.

TABLO III  
ORIJINAL VERİ KÜMESİNDEN OLUŞTURULAN YENİ VERİ KÜMELERİ

Veri Kümesi	Yapılan İşlemler
VeriKümesi#1 (Orijinal veri kümesi)	Orijinal Görüntüler (32'lik Yığınlar)
VeriKümesi#2 (Orijinal veri kümesi)	Orijinal Görüntüler (16'lik Yığınlar)
VeriKümesi#3	Karışık Görüntüler (16'lik Yığınlar)
VeriKümesi#4	(Manipülasyon#1) (16'lik Yığınlar)
VeriKümesi#5	(Manipülasyon#2) (16'lik Yığınlar)
VeriKümesi#6	Orijinal Görüntüler + (VeriArtırma#1) <sup>1</sup> (16'lik Yığınlar)
VeriKümesi#7	Orijinal Görüntüler + (VeriArtırma#1) <sup>2</sup> (16'lik Yığınlar)
VeriKümesi#8	Orijinal Görüntüler + (VeriArtırma#1) <sup>3</sup> (16'lik Yığınlar)
VeriKümesi#9	Orijinal Görüntüler + (VeriArtırma#2) <sup>1</sup> (16'lik Yığınlar)
VeriKümesi#10	Orijinal Görüntüler + (VeriArtırma#3) <sup>1</sup> (16'lik Yığınlar)

<sup>1</sup> Her Sınıfta En Fazla Görüntüye Sahip Sınıfın Görüntü Sayısı Kadar Veri Olacak Şekilde Üretilen Görüntüler, <sup>2</sup> Her Sınıf En Az 100'er Adet Görüntüye Sahip Olacak Şekilde Üretilen Görüntüler, <sup>3</sup> Tüm Sınıfların Ortalama Görüntü Sayısından Az Sayıda Görüntüye Sahip Sınıfların Sahip Olduğu Görüntü Sayısına Oranla Üretilen Görüntüler

### C. Eğitilecek Modellerin Hazırlanması

Bu çalışmada, farklı model mimarilerinin kullanımının başarımlarına etkisini gözlemleyebilmek amaçlı BasicResNet, BasicVGG, EfficientNetB0, EfficientNetB3, EfficientNetB5, EfficientNetV2B0, DenseNet121, InceptionResNetV2, InceptionV3, MobileNetV2, ResNet101, ResNet101V2, VGG-16, VGG-19, Xception modelleri kullanılmıştır. BasicResNet ve BasicVGG modelleri dışındaki diğer modeller transfer öğrenme yöntemiyle eğitilmek üzere önceden eğitilmiş modeller olarak hazırlanmıştır. Bu modellere ImageNet'e ait ağırlıklar yüklenmiş ve sonuna BatchNormalization, Dense, Dropout ve tekrar Dense katmanları eklenerek çalışmaya uygun hale getirilmiştir. Modellerin eğitiminde kullanılacak algoritmaların başarımlarına etkisini gözlemleyebilmek amaçlı, Adam, Adamax, Nadam, RMSprop algoritmaları kullanılmıştır.

## V. DENEYSEL SONUÇLAR

Çalışma kapsamında beyin tümörü sınıflandırması için hazırlanan veri kümeleri farklı modeller üzerinde, 15 sınıf ve 44 sınıf başarımları açısından test edilmiştir. Modeller test edilirken kayıp (loss), doğruluk (accuracy), F1-skoru (F1-score) metrikleri sağlama kümesi üzerinde, kesinlik (precision) ve hassasiyet/duyarlılık (recall) metrikleri test kümesi üzerinde elde edilmiştir. Modeller test edilirken aşağıdaki temel adımlar izlenmiştir:

- 1. **adım:** Önceden eğitilmemiş BasicResNet ve BasicVGG modellerinin tüm veri kümeleri üzerindeki başarımlarının tespit edilmesi, bu oranlara göre en başarılı veri kümesinin tespit edilmesi,
- 2. **adım:** Farklı algoritmaların 1. adımda bulunan en başarılı veri kümesi ile BasicResNet modeli üzerinde test edilmesi sonucu en başarılı algoritmanın tespit edilmesi,
- 3. **adım:** En başarılı veri kümesi ve en başarılı algoritmanın öğrenim aktarımı yapılmış birden çok model üzerinde test edilmesi,
- 4. **adım:** 3. adımda test edilen modellerden en başarılı modellerin birleştirilerek yeni modeller oluşturulması.

Bu kapsamda yukarıda verilen adımlara ait deneysel sonuçlar 15 sınıf ve 44 sınıf başarımları açısından aşağıdaki alt başlıklarda değerlendirilmiştir.

### A. 15 Sınıf İçin Deneysel Sonuçlar

1) **En Başarılı Veri Kümesinin Tespiti (15 Sınıf):** En başarılı veri kümesinin tespiti amaçlı, orijinal veri kümesi VeriKümesi#1'den türetilen diğer tüm veri kümeleri önceden eğitilmemiş BasicResNet ve BasicVGG modelleri üzerinde test edilmiştir. Model Tablo IV'de verilen parametreler ile derlenmiş ve art arda 3 eğitim adımında sağlama kaybı metriği değerlerinde azalma görülmediği takdirde öğrenme oranını onda birine düşüren geri çağırma metodu (ReduceLROnPlateau) kullanılmıştır. Veri kümelerinin bu modeller üzerindeki başarımlar sonuçları Tablo V ve Tablo VI'de verilmiştir.

TABLO IV  
BASICRESNET VE BASICVGG MODELLERİNDE KULLANILAN  
HIPERPARAMETRELER

Modeller	Hiper parametreler
BasicResNet ve BasicVGG	(Adamlearning_rate = 0.001), loss = 'categorical_crossentropy', metrics = ['accuracy', 'F1_score', 'AUC'])

TABLO V  
BASICRESNET MODELİNİN TÜM VERİ KÜMELERİ ÜZERİNDEKİ  
BAŞARIMLARI

Veri Kümeleri	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
VeriKümesi#1	0.295774	<b>0.962798</b>	0.956826	0.9377	0.9360
VeriKümesi#2	0.228934	0.959821	<b>0.963301</b>	<b>0.9491</b>	0.9464
VeriKümesi#3	0.295620	0.946429	0.939006	0.9170	0.9137
VeriKümesi#4	1.523839	0.589286	0.563592	0.6504	0.6250
VeriKümesi#5	0.222365	0.961310	0.962938	0.9383	0.9360
VeriKümesi#6	<b>0.212744</b>	0.953869	0.957213	0.9379	0.9375
VeriKümesi#7	0.248658	0.952381	0.953843	0.9443	0.9435
VeriKümesi#8	0.270058	0.959821	0.959013	0.9347	0.9330
VeriKümesi#9	0.212946	0.958333	0.958900	<b>0.9491</b>	<b>0.9479</b>
VeriKümesi#10	0.248704	0.953869	0.953725	0.9406	0.9405

TABLO VI  
BASICVGG MODELİNİN TÜM VERİ KÜMELERİ ÜZERİNDEKİ  
BAŞARIMLARI

Veri Kümeleri	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
VeriKümesi#1	0.417350	0.925595	0.929378	0.9064	0.9018
VeriKümesi#2	<b>0.291500</b>	<b>0.938988</b>	<b>0.939177</b>	<b>0.9242</b>	<b>0.9211</b>
VeriKümesi#3	0.667534	0.849702	0.851185	0.8655	0.8571
VeriKümesi#4	1.586791	0.443452	0.285970	0.5071	0.4628
VeriKümesi#5	2.451471	0.196429	0.000000	0.0380	0.1949
VeriKümesi#6	0.466503	0.892857	0.898023	0.8936	0.8884
VeriKümesi#7	0.330480	0.928571	0.920182	0.9137	0.9107
VeriKümesi#8	0.353188	0.921131	0.926431	0.9214	0.9182
VeriKümesi#9	0.339385	0.906250	0.911371	0.9104	0.9048
VeriKümesi#10	0.308619	0.927083	0.928280	0.9148	0.9122

Tablo V ve Tablo VI'de elde edilen tüm bu sonuçlar değerlendirildiğinde, BasicResNet ve BasicVGG modellerinde en başarılı sonucu veren veri kümesinin VeriKümesi#2 olduğu tespit edilmiştir ve bir sonraki adımda (en başarılı algoritmanın tespitinde) kullanılacak veri kümesi olarak seçilmiştir.

2) **En Başarılı Algoritmanın Tespiti (15 Sınıf):** VeriKümesi#2 önceden eğitilmemiş BasicResNet modeli üzerinde test edilmiştir. Model yine Tablo IV'de verilen parametreler ile derlenmiş ancak optimizasyon algoritması olarak sırasıyla Adam, Adamax, Nadam ve RMSprop

kullanılmıştır. Algoritmaların bu model üzerindeki sonuçları Tablo VII’de verilmiştir. Tablodan da görüleceği gibi, BasicResNet modeli üzerinde Adam algoritmasının kullanılan diğer algoritmalarından daha başarılı olduğu gözlemlenmiştir, bu nedenle en başarılı algoritma olarak seçilmiştir.

TABLO VII  
BASICRESNET MODELİ BAŞARIM ORANLARI

Algoritma	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
Adam	<b>0.228934</b>	<b>0.959821</b>	<b>0.963301</b>	<b>0.9491</b>	<b>0.9464</b>
Adamax	0.287929	0.956845	0.959004	0.9347	0.9315
Nadam	0.290091	<b>0.959821</b>	0.956976	0.9339	0.9330
RMSprop	0.236017	0.955357	0.953002	0.9372	0.9360

3) *En Başarılı Modelin Tespiti (15 Sınıf):* VeriKümesi#2 öğrenim aktarımı yapılmış modeller üzerinde Adam algoritması kullanılarak test edilmiştir. Modellerin başarımları Tablo VIII’de verilmiş olup, tablodan da görüleceği gibi EfficientNetB0, EfficientNetB5 ve DenseNet121 modelleri bu veri kümesi üzerinde en başarılı sonuçları vermiştir.

TABLO VIII  
ÖĞRENİM AKTARIMI YAPILMIŞ MODELLERİN VERİKÜMESİ#2 ÜZERİNDE BAŞARIM ORANLARI

Model	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
ResNet101	1.693420	0.568452	0.516466	0.5267	0.5804
ResNet101V2	2.647365	0.196429	0.015625	0.0380	0.1949
VGG-16	0.614313	0.907738	0.901942	0.8690	0.8676
VGG-19	1.398443	0.700893	0.647628	0.6910	0.7113
EfficientNetB0	0.163977	<b>0.992560</b>	0.989439	0.9773	0.9762
EfficientNetB3	0.203364	0.985119	0.986511	0.9755	0.9747
EfficientNetB5	0.207336	0.988095	0.988719	<b>0.9840</b>	<b>0.9836</b>
EfficientNetV2B0	0.181949	0.983631	0.984159	0.9786	0.9777
InceptionResNetV2	0.278375	0.977679	0.973105	0.9561	0.9539
InceptionV3	1.226397	0.794643	0.763903	0.7912	0.7917
MobileNetV2	0.254908	0.968750	0.969848	0.9753	0.9747
DenseNet121	<b>0.145379</b>	<b>0.992560</b>	<b>0.990879</b>	0.9695	0.9688
Xception	0.202946	0.982143	0.981756	0.9676	0.9673

4) *Model Birleştirme Yapılarak Sonuçların İyileştirilmesi (15 Sınıf):* VeriKümesi#2’nin eğitim kümesi ile eğitilip kaydedilen en iyi 3 model (EfficientNetB0, EfficientNetB5, DenseNet121) birleştirilerek yeni birleşik modeller üretilmiştir.

TABLO IX  
BİRLEŞİK MODELLER VERİKÜMESİ#2 ÜZERİNDE BAŞARIM ORANLARI

Model	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
BirleşikModel#1 (EfficientNetB0 + EfficientNetB5)	0.312591	0.994048	<b>0.993952</b>	0.9841	0.9836
BirleşikModel#2 (EfficientNetB5 + DenseNet121)	0.292271	0.994048	0.993183	0.9840	0.9836
BirleşikModel#3 (EfficientNetB0 + DenseNet121)	<b>0.255541</b>	<b>0.995536</b>	0.993136	0.9827	0.9821
BirleşikModel#4 (EfficientNetB0 + EfficientNetB5 + DenseNet121)	0.407540	<b>0.995536</b>	0.993903	<b>0.9869</b>	<b>0.9866</b>

Birleşik modellerin VeriKümesi#2 üzerindeki başarımları Tablo IX’de verilmiştir. Tablodan da görüldüğü gibi en yüksek başarımlı oranı, en yüksek başarımlı önceden eğitilmiş modelleri birleştirilerek elde edilmiştir. En başarılı iki modelin (EfficientNetB0 + DenseNet121) birleşiminden oluşan BirleşikModel#3’ün birleşik modeller içerisinde en düşük kayıp ve en yüksek doğruluk oranını verdiği gözlemlenmiştir. En yüksek kesinlik ve hassasiyet oranına sahip olan EfficientNetB5 modeli de bu birleştirme işlemine eklendiğinde doğruluk oranında bir değişim olmasa da kesinlik ve hassasiyet oranlarının yükseldiği gözlemlenmiştir.

## B. 44 Sınıf İçin DeneySEL Sonuçlar

### 1) En Başarılı Veri Kümesinin Tespiti (44 Sınıf):

En başarılı veri kümesinin tespiti amaçlı, orijinal veri kümesi VeriKümesi#1’den türetilen diğer tüm veri kümeleri önceden eğitilmemiş BasicResNet ve BasicVGG modelleri üzerinde test edilmiştir. Model Tablo IV’de verilen parametreler ile derlenmiş ve art arda 3 eğitim adımında sağlama kaybı metriği değerlerinde azalma görülmediği takdirde öğrenme oranını onda birine düşüren geri çağırım metodu (ReduceLROnPlateau) kullanılmıştır. Veri kümelerinin bu modeller üzerindeki başarımları Tablo X ve Tablo XI’de verilmiştir. Tablolarda verilen tüm bu sonuçlar değerlendirildiğinde, BasicResNet ve BasicVGG modellerinde en başarılı sonucu veren veri kümesinin VeriKümesi#10 olduğu tespit edilmiştir ve bir sonraki adımda (en başarılı algoritmanın tespitinde) kullanılacak veri kümesi olarak seçilmiştir. Burada, veri kümesindeki veri sayılarının dengesizliğinin model başarımlarındaki olumsuz etkileri azaltmak için kullanılan veri artırma işlemlerinin olumlu sonuçlar verdiği gözlemlenmiştir.

TABLO X  
BASICRESNET MODELİNİN TÜM VERİ KÜMELERİ ÜZERİNDEKİ BAŞARIMLARI

Veri Kümesi	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
VeriKümesi#1	0.588331	0.921131	0.903591	0.8990	0.8943
VeriKümesi#2	0.477324	0.938988	0.934136	0.9033	0.9018
VeriKümesi#3	0.909766	0.875000	0.859285	0.8764	0.8571
VeriKümesi#4	2.183161	0.486607	0.404804	0.4481	0.4836
VeriKümesi#5	0.462331	0.936012	0.920599	0.9216	0.9211
VeriKümesi#6	0.355092	<b>0.940476</b>	0.935179	0.9057	0.9033
VeriKümesi#7	0.489300	0.931548	0.926720	0.8990	0.8958
VeriKümesi#8	1.050116	0.854167	0.849665	0.8637	0.8333
VeriKümesi#9	0.355204	0.927083	0.927959	0.9093	0.9092
VeriKümesi#10	<b>0.297403</b>	<b>0.940476</b>	<b>0.942407</b>	<b>0.9321</b>	<b>0.9315</b>

TABLO XI  
BASICVGG MODELİNİN TÜM VERİ KÜMELERİ ÜZERİNDEKİ BAŞARIMLARI

Veri Kümesi	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
VeriKümesi#1	0.639560	<b>0.866071</b>	0.859989	0.8295	0.8244
VeriKümesi#2	0.619324	0.860119	0.857904	<b>0.8561</b>	<b>0.8482</b>
VeriKümesi#3	0.794665	0.812500	0.808047	0.7950	0.7961
VeriKümesi#4	1.955100	0.446429	0.341275	0.3839	0.4539
VeriKümesi#5	3.478352	0.083333	0.000000	0.0067	0.0818
VeriKümesi#6	0.656658	0.813988	0.826846	0.8317	0.8244
VeriKümesi#7	0.591548	0.846726	0.855482	0.8417	0.8423
VeriKümesi#8	0.623151	0.830357	0.844599	0.8359	0.8229
VeriKümesi#9	0.717691	0.799107	0.812786	0.7603	0.7604
VeriKümesi#10	<b>0.547314</b>	0.864583	<b>0.862482</b>	0.8494	0.8363

### 2) En Başarılı Algoritmanın Tespiti (44 Sınıf):

VeriKümesi#10 önceden eğitilmemiş BasicResNet modeli üzerinde test edilmiştir. Model yine Tablo IV’de verilen parametreler ile derlenmiş ancak optimizasyon algoritması olarak sırasıyla Adam, Adamax, Nadam ve RMSprop kullanılmıştır. Algoritmaların bu model üzerindeki sonuçları Tablo XII’de verilmiştir. Tablodan da görüleceği gibi, BasicResNet modeli üzerinde Adam algoritmasının kullanılan diğer algoritmalarından daha başarılı olduğu gözlemlenmiştir bu nedenle en başarılı algoritma olarak seçilmiştir.

3) *En Başarılı Modelin Tespiti (44 Sınıf):* VeriKümesi#10 öğrenim aktarımı yapılmış modeller üzerinde Adam algoritması kullanılarak test edilmiştir. Modellerin başarımları

TABLO XII  
BASICRESNET MODELİ BAŞARIM ORANLARI

Algoritma	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
Adam	<b>0.297403</b>	<b>0.940476</b>	<b>0.942407</b>	<b>0.9321</b>	<b>0.9315</b>
Adamax	0.400537	<b>0.940476</b>	0.941241	0.9125	0.9122
Nadam	0.318992	0.938988	0.932558	0.9017	0.9018
RMSprop	0.327640	0.931548	0.930514	0.9102	0.9092

Tablo XIII’de verilmiş olup, tablodan da görüleceği gibi EfficientNetB0, EfficientNetB3 ve EfficientNetB5 modelleri bu veri kümesi üzerinde en başarılı sonuçları vermiştir.

TABLO XIII  
ÖĞRENİM AKTARIMI YAPILMIŞ MODELLERİN VERİKÜMESİ#10 ÜZERİNDE BAŞARIM ORANLARI

Model	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
ResNet101	0.534052	0.922619	0.921055	0.8997	0.8943
ResNet101V2	0.508187	0.915179	0.913707	0.9006	0.8988
VGG-16	0.743422	0.880952	0.872633	0.8641	0.8616
VGG-19	0.922323	0.833333	0.816393	0.8431	0.8348
EfficientNetB0	<b>0.229881</b>	<b>0.979167</b>	<b>0.979695</b>	<b>0.9547</b>	<b>0.9524</b>
EfficientNetB3	0.268722	0.971726	0.972776	<b>0.9562</b>	<b>0.9539</b>
EfficientNetB5	0.303306	0.973214	0.974990	0.9506	0.9479
EfficientNetV2B0	0.301354	0.967262	0.968414	0.9457	0.9420
InceptionResNetV2	0.410661	0.941964	0.945065	0.9327	0.9315
InceptionV3	0.330869	0.952381	0.949542	0.9328	0.9345
MobileNetV2	0.307161	0.956845	0.958621	0.9395	0.9360
DenseNet121	0.260753	0.965774	0.965246	0.9493	0.9509
Xception	0.287010	0.967262	0.968984	0.9399	0.9420

4) Model Birleştirme Yapıların İyileştirilmesi (44 Sınıf): VeriKümesi#10’un eğitim kümesi ile eğitilip kaydedilen en iyi 3 model (EfficientNetB0, EfficientNetB3, EfficientNetB5) birleştirilerek yeni modeller üretilmiştir.

TABLO XIV  
BİRLEŞİK MODELLER VERİKÜMESİ#10 ÜZERİNDE BAŞARIM ORANLARI

Model	Kayıp	Doğruluk	F1-skoru	Kesinlik	Hassasiyet
BirleşikModel#5 (EfficientNetB0 + EfficientNetB3)	<b>0.329605</b>	0.979167	0.980559	0.9544	0.9524
BirleşikModel#6 (EfficientNetB3 + EfficientNetB5)	0.400022	0.980655	0.980316	0.9606	0.9583
BirleşikModel#7 (EfficientNetB0 + EfficientNetB5)	0.382564	0.977679	0.981855	0.9561	0.9539
BirleşikModel#8 (EfficientNetB0 + EfficientNetB3 + EfficientNetB5)	0.498574	<b>0.983631</b>	<b>0.983391</b>	<b>0.9617</b>	<b>0.9598</b>

Birleşik modellerin VeriKümesi#10 üzerindeki başarımları Tablo XIV’de verilmiştir. Tablodan da görüldüğü gibi en yüksek başarımları oranı, en yüksek başarımları oranlı önceden eğitilmiş modelleri birleştirilerek elde edilmiştir. En başarılı üç modelin (EfficientNetB0 + EfficientNetB3 + EfficientNetB5) birleşiminden oluşan BirleşikModel#8’in en yüksek doğruluk, f1-skoru, kesinlik ve hassasiyet oranını verdiği gözlemlenmiştir. En başarılı iki modelin (EfficientNetB0 + EfficientNetB3) birleştirilmesiyle oluşturulan BirleşikModel#5’in ise birleşik modeller arasında en düşük kayıp oranını verdiği gözlemlenmiştir.

## VI. SONUÇ VE İLERİKİ ÇALIŞMALAR

Bu çalışmada, beyin MR görüntüleri üzerinde beyin tümörü sınıflandırması amaçlı derin öğrenme algoritmalarını kullanan beyin tümörü sınıflandırma modelleri test edilmiştir. 14 farklı beyin tümörü, 15 sınıf ve 44 sınıf için öğrenme aktarımı kullanılarak tahminlenmiştir. Elde edilen sonuçlara göre bu veri kümesi için, seçilen hiperparametreler göz önünde bulundurulduğunda, hem 15 sınıf hem de 44 sınıf için birleştirilmiş derin öğrenme modellerinin başarımları metrikleri göz önüne alındığında en başarılı sınıflandırmayı yaptığı gözlemlenmiştir.

İleriki çalışmalarda, beyin MR görüntüsü içeren birden fazla veri kümesi ile eğitilmiş bir sınıflandırma modeli geliştirilerek bu modelin farklı veri kümeleri üzerinde test edilmesi amaçlanmaktadır.

## KAYNAKÇA

- [1] S. Chatterjee, F. A. Nizamani, A. Nürnberger, and O. Speck, “Classification of brain tumours in mr images using deep spatiotemporal models,” *Scientific Reports*, vol. 12, no. 1, p. 1505, 2022.
- [2] “Brain Tumor MRI Images 44 Classes,” <https://www.kaggle.com/datasets/fernando2rad/brain-tumor-mri-images-44c/code>, accessed: 2023-06-06.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.
- [4] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *arXiv preprint arXiv:1409.1556*, 2014.
- [5] M. Tan and Q. Le, “Efficientnet: Rethinking model scaling for convolutional neural networks,” in *International conference on machine learning*. PMLR, 2019, pp. 6105–6114.
- [6] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4700–4708.
- [7] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, “Inception-v4, inception-resnet and the impact of residual connections on learning,” in *Proceedings of the AAAI conference on artificial intelligence*, vol. 31, no. 1, 2017.
- [8] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, “Rethinking the inception architecture for computer vision,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 2818–2826.
- [9] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, “Mobilenetv2: Inverted residuals and linear bottlenecks,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 4510–4520.
- [10] F. Chollet, “Xception: Deep learning with depthwise separable convolutions,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 1251–1258.
- [11] “BrainTumorClassification,” <https://github.com/ibrahim-ince/BrainTumorClassification>, accessed: 2023-06-06.
- [12] M. F. Alanazi, M. U. Ali, S. J. Hussain, A. Zafar, M. Mohatram, M. Irfan, R. AlRuwalli, M. Alruwalli, N. H. Ali, and A. M. Albarrak, “Brain tumor/mass classification framework using magnetic-resonance-imaging-based isolated and developed transfer deep-learning model,” *Sensors*, vol. 22, no. 1, p. 372, 2022.
- [13] “Brain Tumor Dataset,” <https://radiopaedia.org/>, accessed: 2023-06-06.
- [14] “Figshare: Brain Tumor Dataset,” [https://figshare.com/articles/dataset/brain\\_tumor\\_dataset/1512427](https://figshare.com/articles/dataset/brain_tumor_dataset/1512427), accessed: 2023-06-06.
- [15] M. Artzi, E. Redmard, O. Tzemach, J. Zeltser, O. Gropper, J. Roth, B. Shofty, D. A. Kozyrev, S. Constantini, and L. Ben-Sira, “Classification of pediatric posterior fossa tumors using convolutional neural network and tabular data,” *IEEE Access*, vol. 9, pp. 91 966–91 973, 2021.
- [16] M. A. Gómez-Guzmán, L. Jiménez-Beristáin, E. E. García-Guerrero, O. R. López-Bonilla, U. J. Tamayo-Perez, J. J. Esqueda-Elizondo, K. Palomino-Vizcaino, and E. Inzunza-González, “Classifying brain tumors on magnetic resonance imaging by using convolutional neural networks,” *Electronics*, vol. 12, no. 4, p. 955, 2023.
- [17] “Brain Tumor MRI Dataset,” <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>, accessed: 2023-06-06.
- [18] “Brain Tumor Classification (MRI),” <https://www.kaggle.com/datasets/sartajbhuvaji/brain-tumor-classification-mri>, accessed: 2023-06-06.
- [19] “Br35H :: Brain Tumor Detection 2020,” <https://www.kaggle.com/datasets/ahmedhamada0/brain-tumor-detection?select=no>, accessed: 2023-06-06.
- [20] E. Irmak, “Multi-classification of brain tumor mri images using deep convolutional neural network with fully optimized framework,” *Iranian Journal of Science and Technology, Transactions of Electrical Engineering*, vol. 45, no. 3, pp. 1015–1036, 2021.
- [21] “RIDER NEURO MRI,” <https://wiki.cancerimagingarchive.net/display/Public/RIDER+NEURO+MRI>, accessed: 2023-06-06.
- [22] “REMBRANDT,” <https://wiki.cancerimagingarchive.net/display/Public/REMBRANDT>, accessed: 2023-06-06.

- [23] "The Cancer Genome Atlas Low Grade Glioma Collection (TCGA-LGG)," <https://wiki.cancerimagingarchive.net/pages/viewpage.action?pageId=5309188>, accessed: 2023-06-06.
- [24] M. Rasool, N. A. Ismail, W. Boulila, A. Ammar, H. Samma, W. M. Yafooz, and A.-H. M. Emara, "A hybrid deep learning model for brain tumour classification," *Entropy*, vol. 24, no. 6, p. 799, 2022.
- [25] N. F. Aurna, M. A. Yousuf, K. A. Taher, A. Azad, and M. A. Moni, "A classification of mri brain tumor based on two stage feature level ensemble of deep cnn models," *Computers in Biology and Medicine*, vol. 146, p. 105539, 2022.
- [26] "SARTA," <https://www.kaggle.com/sarta>, accessed: 2023-06-06.
- [27] "brain-tumor-dataset," <https://www.kaggle.com/datasets/mohamedmetwalysheif/braintumordataset>, accessed: 2023-06-06.
- [28] A. Raza, H. Ayub, J. A. Khan, I. Ahmad, A. S. Salama, Y. I. Daradkeh, D. Javeed, A. Ur Rehman, and H. Hamam, "A hybrid deep learning-based approach for brain tumor classification," *Electronics*, vol. 11, no. 7, p. 1146, 2022.